MEMORIA DE PREDICCIÓN DE PARADAS EN BOXES EN FÓRMULA 1 MEDIANTE APRENDIZAJE AUTOMÁTICO

Autores:

- César de Esteban Elvira
- Maël Humberto García
- Daniel Rodríguez Rodríguez
- Álvaro Turiégano Moreno

ÍNDICE

1. Resumen
2. Introducción
3. Descripción de la solución planteada
4. Experimentación
5. Resultados
6. Conclusiones y posibles mejoras (Trabajos futuros)
7. Referencias utilizadas
8. Anexo con las tareas realizadas por cada miembro del grupo

1. Resumen

En esta práctica abordamos el problema de la predicción de las paradas de boxes en las carreras de Fórmula. Usaremos técnicas de aprendizaje automático vistos en las clases de Sistemas Inteligentes. Nuestro objetivo será usar varios modelos distintos que intentarán predecir si un piloto hará una parada en determinada vuelta, basándonos en los datos de las carreras recogidos enel siguiente conjunto de datos almacenados en el siguiente enlace, https://www.kaggle.com/datasets/aadigupta1601/f1-strategy-dataset-pit-stop-prediction.

Para ello, primero hemos hecho un proceso de limpieza y preprocesamiento del dataset. Después hemos implementado y comparado los distintos algoritmos de machine learning que hemos aprendido en clase y para finalizar, hemos hecho un análisis en base a los resultados obtenidos.

2. Introducción

La fórmula es un deporte en el que las estrategias son vitales. Decidir cuándo realizar una parada en boxes puede suponer la diferencia entre la victoria y la derrota. Hay múltiples factores que influyen en esta decisión, como puede ser el desgaste de los neumáticos, el estado de la pista, las posiciones de los rivales directos, etc.

La predicción de estas parada son interesantes ya que:

- Tienen un impacto directo en las estrategias de la carrera,
- Permite aplicar técnicas de machine learning en datos deportivos.
- Afecta a un problema de toma de decisiones.

En los últimos años, múltiples deportes como el fútbol o el baloncesto han ido incrementando el uso de datos para análisis predictivos, pero el deporte donde podría ser más crucial es en la Fórmula 1.

El objetivo de esta práctica es comprobar de forma empírica si los modelos de aprendizaje automático son capaces de predecir si un piloto hará o no una parada en boxes en una vuelta concreta. Este ha sido un tema ya explorado por muchas personas y existen multitud de investigaciones que respaldan esta afirmación como pueden ser aquellos denostados en el apartado 7.

3. Descripción de la solución planteada

Hemos usados un dataset que contiene información de múltiples carreras de Fórmula 1 donde destacan las siguientes variables:

- Número actual de la vuelta
- Posición del piloto en la carrera
- Tiempo por vuelta y sus deltas (diferencias de tiempo)

- El estado y compuesto de los neumáticos

Antes de realizar ningún cálculo o acción hemos llevado a cabo una limpieza de los datos donde hemos:

- Eliminado datos con valores nulos o incompletos
- Normalizado algunos datos numéricos (principalmente para aquellos modelos sensibles a grandes distancias entre datos como KNN o redes neuronales)
- Eliminado las columnas irrelevantes que sólo creaban ruido al modelo

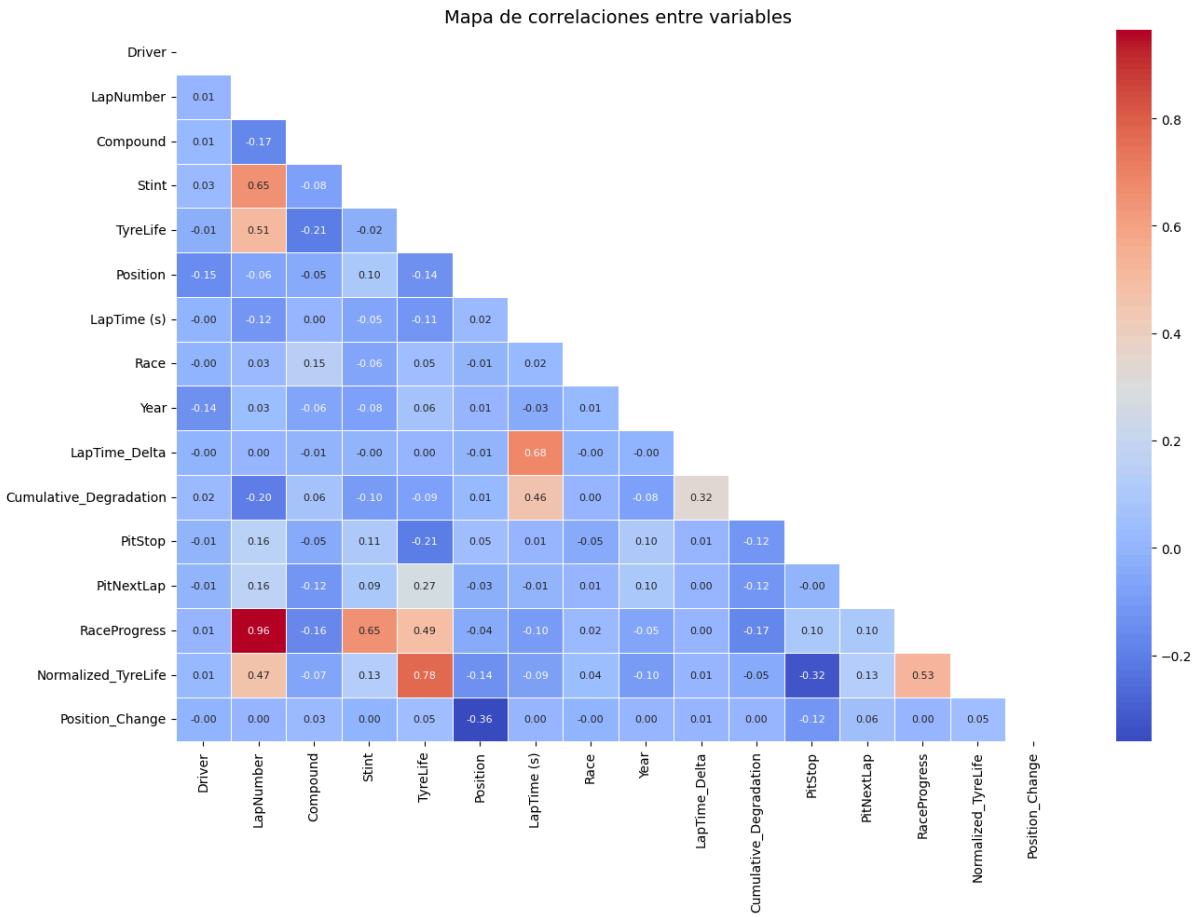

Gráfico 1: Mapa de correlaciones entre variables

Esta selección de por ejemplo las columnas irrelevantes se pueden observar en el Gráfico 1 donde se puede observar la gran relación existente entre el progreso de la carrera y el número de vueltas, haciendo que estas dos variables sean esencialmente iguales.

Para saber si se ejecuta o no una parada en boxes, hemos definido una variable binaria donde el valor 1 indica la parada en boxes y el valor 0 indica que no hay parada.

4. Experimentación

Para el proceso de experimentación hemos planteado usar llos siguientes modelos:

- Regresión logística
- K-Nearest Neighbors (KNN)
- Árbol de Decisión
- Random Forest
- Red Neuronal (MLP)
- SVM
- Perceptron

Durante la fase de entrenamiento hemos realizado una exploración y ajuste de los hiperparámetros de estos algoritmos para mejorar el rendimiento (el número de estimadores y la profundidad máxima en Random Forest o el número de vecinos K, en KNN).

Para la evaluación de los modelos hemos usado diversas métricas:

- **Accuracy (Exactitud):** Porcentaje total de aciertos.
- **Precision (Precisión):** Proporción de predicciones positivas correctas frente al total de predicciones positivas.
- **Recall (Sensibilidad):** Proporción de casos positivos reales que fueron identificados correctamente.
- **F1-score:** Media armónica entre Precision y Recall (especialmente útil si el dataset está desbalanceado).
- **ROC AUC:** Área bajo la curva Característica Operativa del Receptor.

5. Resultados

Hemos decidido escoger como mejor solución el modelo predictivo K-Nearest Neighbors (KNN) ya que este algoritmo ha demostrado un rendimiento superior al resto alcanzando unos valores superiores en todos los casos al 97%. Dicha información se puede comprobar en la Tabla 1.

El éxito de KNN en este contexto se puede justificar teóricamente porque las paradas en boxes se realizan bajo condiciones muy concretas y repetitivas y la ser un algoritmo basado en el cálculo de distancias es capaz de clasificar buscando las vueltas históricas más similares (lo que vienen a ser sus vecinos cercanos).

Hay otros algoritmos que también han obtenido buenos resultados, pero ninguno se llega a acercar la precisión de KNN. Esto se puede deber a múltiples causas pero para el trabajo actual esta última es la tecnología que mejor se adapta al problema.

	Accuracy	Precision	Recall	F1	ROC-AUC
KNN	0.9705	0.9711	0.9705	0.9704	0.9939
Random Forest	0.8726	0.8746	0.8726	0.8724	0.9467
Red Neuronal (MLP)	0.8602	0.8614	0.8602	0.8601	0.9323
Árbol de Decisión	0.8201	0.8214	0.8201	0.8199	0.8958
Regresión Logística	0.7830	0.7832	0.7830	0.7830	0.8578
Perceptron	0.6768	0.6772	0.6768	0.6767	0.7475
SVM	0.5723	0.6206	0.5723	0.5236	0.6431

Tabla 1: Estadísticas de los modelos de predicción.

Todo este se puede ver más gráficamente en la Imagen 1, donde se pueden observar para cada modelo como fueron las predicciones. En la parte superior izquierda de cada cuadrado podemos ver la cantidad de predicciones que fueron no junto al número de veces reales donde no se paró, y en la inferior derecha donde se predijo que se sí se paraba y se paró. Esto corresponde a los aciertos de los modelos y en casi todos las predicciones sobre no parar se acierta mucho ya que en las carreras hay muchas vueltas en las que no se para entonces si se predijese que no se para en ningún momento se acertaría bastante pero el modelo no es correcto por esto sino por la cantidad de predicciones en las que se dice que sí se para y se acierta esta predicción.

El resto de cuadrantes son fallos del modelo bien porque se predice que se para y no se para en la realidad o porque se para sin predecirlo. Esta parte es interesante ya que nos dice si el modelo es muy pasivo o activo y falla por no intentarlo o por intentarlo demasiado.

La Tabla 1 nos es de utilidad para saber la precisión y otras estadísticas de los modelos y para decidir con cuál nos quedamos, pero la Imagen 1 nos da una imagen más completa de la situación apoyándonos no solo en saber cual es el mejor modelo, sino en saber cómo fallan estos modelos (incluyendo al mejor) y dándonos información adicional sobre cómo tratar los posibles fallos de los mismos.

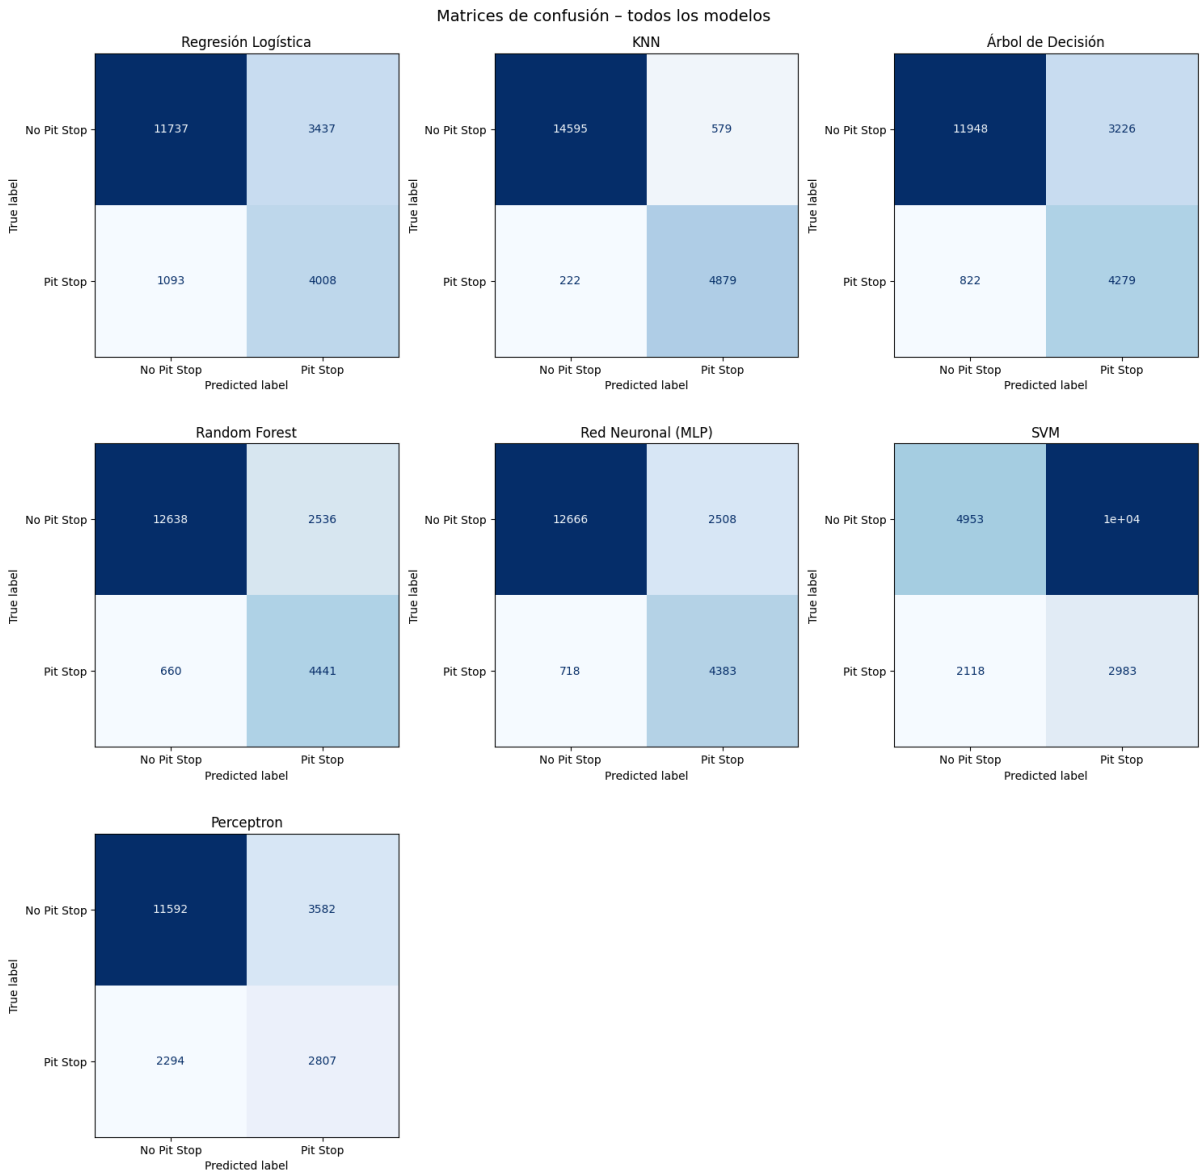

Imagen 1: Fallos y aciertos de las pruebas en función del resultado y la predicción

Al tener tanta precisión el algoritmo podría ser usado como anticipación estratégica para los equipos, sabiendo que es la táctica más probable que realizarán los rivales pudiendo culminar en protecciones contra undercuts, la cual es una estrategia para llamar a un piloto a boxes con anterioridad para aprovechar neumáticos nuevos para reducir distancias, o cualquier otra estrategia que pudieran llevarse a cabo por los distintos equipos.

6. Conclusiones y posibles mejoras (Trabajos futuros)

Las conclusiones que hemos obtenido de esta práctica es que es posible predecir las paradas que se efectúan en una carrera de Fórmula 1 utilizando técnicas de machine

learning. Los modelos son capaces de capturar patrones subyacentes en la degradación de neumáticos y los tiempos por vuelta para anticipar la toma de decisiones estratégicas.

Como trabajo futuro, se podrían realizar ajustes más precisos de los hiperparámetros. También se podrían incorporar nuevas variables, como podrían ser:

- Condiciones climatológicas
- Miembros del equipo
- Habilidad de cierto piloto en una pista concreta
- Estrategias regulares preferidas según la escudería

7. Referencias utilizadas

kaeldrin-gh/f1-pitstop: A comprehensive F1 pit stop strategy optimization application featuring an end-to-end data pipeline, machine learning models, and interactive Streamlit dashboard.

rembertdesigns/pit-stop-simulator: An interactive F1 race simulator using Reinforcement Learning (PPO, Q-learning) and Streamlit to optimize pit stop strategies based on dynamic conditions.

8. Anexo con las tareas realizadas por cada miembro del grupo

- Maël Humberto García y César de Esteban Elvira: Redacción de la memoria, codificación 2 modelos y realización presentación.
- Daniel Rodríguez Rodríguez: Redacción de la memoria y del JupiterNotebook
- Álvaro Turiégano Moreno: Codificación del programa y redacción JupiterNotebook